Sistema de recuperación de imágenes por características

Planeación, datos y detección

Juan Ulises Calderon Huerta

12 de octubre de 2026

Índice

1. Objetivo y alcance **3**

2. Equipo de pruebas **3**

3. Datos **3**

3.1. VeRi-776 . . . 3

3.2. Global Streetscapes . . . 4

3.3. V1: fondos COCO (histórico) . . . 5

3.4. Generador V2 . . . 5

3.5. Limitaciones y riesgos . . . 5

3.6. Reproducibilidad . . . 6

4. Registro de decisiones **6**

5. Detección con YOLO26 **7**

5.1. Protocolo de evaluación . . . 7

6. Descriptores **7**

6.1. Atributos fijos . . . 7

6.2. Descripción generativa . . . 8

7. Base de datos **8**

8. LocateAnything **8**

9. Resultados **8**

9.1. Detección con YOLO26 sobre el dataset sintético . . . 8

9.2. Resto de resultados . . . 8

10. Bitácora de experimentos **9**

11. Conclusiones **9**

1. Objetivo y alcance

El proyecto estudia un sistema de recuperación de imágenes de vehículos mediante descriptores visuales. Se comparan dos enfoques: (A) *atributos fijos*, producidos por un clasificador multicabeza de color y tipo de vehículo, y (B) *descripciones generadas* por un modelo visión–lenguaje. La localización se realiza con YOLO26 en sus variantes `n` y `s`, y los resultados se guardarán en MongoDB. El dataset principal es VeRi-776; DeepFashion queda fuera del alcance actual. La fecha límite del proyecto es el 9 de noviembre de 2026.

Incluido: atributos fijos (color y tipo), descripción generada, localización con YOLO26, dataset sintético para evaluar la detección, prueba secundaria con LocateAnything, base de datos con consultas por características y comparación de calidad, latencia y memoria.

Fuera de alcance: ajuste fino de modelos generativos, detector entrenado desde cero, búsqueda con embeddings y despliegue.

2. Equipo de pruebas

Componente	Especificación
CPU	Intel Core i7-10750H @ 2.60 GHz
GPU	NVIDIA GeForce RTX 2070 Max-Q (8 GB de VRAM)
RAM	16 GB
Almacenamiento	SSD NVMe de 1 TB

Tabla 1: Equipo de pruebas.

La generación del dataset sintético debe poder ejecutarse sin GPU.

3. Datos

3.1. VeRi-776

VeRi es el dataset principal. Sus imágenes son recortes de vehículos de cámaras de vigilancia, por lo que la caja de un vehículo pegado en una escena sintética es el rectángulo completo del recorte. Las anotaciones XML están en codificación `gb2312` y el lector las decodifica de forma explícita. No hay solapamiento de identidades entre *train* y *test*, el generador usa solo *test* por defecto y en *test* no hay ejemplos del tipo `mpv`.

Partición	Imágenes	Identidades	Ancho med.	Alto med.	Área med. (px^2)
train	37 746	575	221	192	41 990
test	11 579	200	222	195	42 823
query	1 678	200	283	254	72 339

Tabla 2: Particiones de VeRi. Medianas en píxeles.

La estimación inicial de tamaños (50–900 px, mediana 283 y p95 cercano a 500) corresponde a la partición *query*, no a *test*. Las estadísticas completas se generan en `artifacts/dataset_stats/dataset_stats.`

Medida (test)	Mín.	p5	p25	Mediana	p75	p95	Máx.
Ancho (px)	55	117	171	222	288	457	917
Alto (px)	44	97	144	195	266	414	839
Área (px^2)	2 904	11 967	25 560	42 823	76 041	165 222	674 041
Ancho/alto	0.49	0.73	0.95	1.13	1.34	1.90	3.19

Tabla 3: Distribución de tamaños en la partición de prueba (11 579 imágenes).

Color	Imágenes
black	3 884
white	2 520
gray	1 822
red	1 099
yellow	760
green	716
blue	299
brown	189
golden	172
orange	118

Tipo	Imágenes
sedan	5 100
suv	2 455
truck	1 830
hatchback	763
pickup	677
bus	352
van	306
estate	96

Tabla 4: Color y tipo en la partición de prueba de VeRi.

3.2. Global Streetscapes

Global Streetscapes (NUS Urban Analytics Lab) reune imágenes de calle de Mapillary y KartaView. Se usaron los archivos `contextual.csv` y `metadata_common_attributes.csv`, con estos criterios: sin panorámicas, iluminación diurna, calidad buena, plataforma de conducción, proyección en perspectiva y lado menor de al menos 640 px. Se muestreó el 1 % de las filas que pasan el filtro, con semilla 0, solicitando 2 500 filas para conservar 2 000 válidas.

La descarga se hizo con el script oficial `download_jpegs.py`, fuera de este repositorio y sin guardar tokens ni credenciales. La verificación registró 2 500 seleccionadas, 2 414 válidas, 86 faltantes y 0 corruptas. En las 2 414 válidas, el lado menor máximo es 4 176 px; se conservaron las primeras 2 000 válidas, cuyo máximo es 3 456 px (1 659 de Mapillary y 341 de KartaView).

Atributo	Valores en las 2 000 imágenes
Clima	clear 1 107; cloudy 636; snowy 227; rainy 26; foggy 4
Dirección de vista	front/back 1 643; side 357
Reflejo en parabrisas	sí 797; no 1 203
Deslumbramiento	sí 24; no 1 976
Plataforma, iluminación, calidad	driving surface, day, good (2 000)
Panorámica, proyección	no, perspective (2 000)

Tabla 5: Atributos contextuales del subconjunto de Streetscapes.

La licencia queda *pendiente de verificar*: Hugging Face indica `cc-by-sa-4.0`, el sitio del proyecto indica CC BY 4.0 y la licencia de las imágenes de origen no se ha verificado. VeRi es de uso no

	Mín.	p5	p25	Mediana	p75	p95	p99	Máx.
Lado menor (px)	720	1 080	1 080	1 152	1 536	2 160	3 024	3 456

Tabla 6: Resolución de las 2 000 imágenes de fondo conservadas.

comercial, por lo que los datos se tratan como internos.

3.3. V1: fondos COCO (histórico)

La V1 fue una prueba con COCO val2017: tres grupos de fondos (`urbano`, `negativo_dificil` y `generico`), exclusión de imágenes con `car`, `motorcycle`, `bus`, `truck` o `train`, y 45 fondos en total (4, 18 y 23). Generó 100 PNG de 640×640 con etiquetas YOLO y manifiesto JSONL. Sus fondos y resultados ya no se conservan en el árbol de datos; esta sección guarda el registro experimental, no una ruta operativa.

COCO se abandonó por tres razones: algunas escenas no tenían relación con vehículos (gatos, cocinas); solo se obtuvieron 45 fondos; y los umbrales de tamaño de COCO no describen bien este lienzo, ya que 96^2 px^2 es el 2.25 % de 640^2 px^2 y vehículos marcados como "grande" se veían pequeños. La hipótesis de que el filtro de lado menor ≥ 640 explica la escasez de fondos (las imágenes de COCO miden alrededor de 640 px en su lado mayor) no se ha confirmado.

3.4. Generador V2

La V2 usa un fondo de Streetscapes por escena, sin collage. En el modo `resize_crop` el fondo se escala para cubrir el lienzo y se recorta una ventana cuadrada aleatoria; en `native_crop` se toma una ventana de 640×640 sin redimensionar. El lienzo es de 640×640 píxeles y las imágenes se guardan en PNG.

El vehículo es un recorte rectangular completo de VeRi (identidades de *test*). La fracción objetivo del área del lienzo se muestrea de forma uniforme entre 40 % y 60 %, y el recorte se reescala con

$$s = \sqrt{A_{\text{objetivo}} / A_{\text{original}}},$$

ampliando o reduciendo, sin tope por defecto y con una sola operación de remuestreo. Si por su relación de aspecto un recorte no cabe en el lienzo, se rechaza y se prueba otro. No se repite ninguna imagen de VeRi dentro de una ejecución, y hay un vehículo por escena.

Se generan dos variantes con idéntica geometría: `matched`, que desenfoca el fondo con factor $b = \min(s, 4)$ (se reduce el fondo a $1/b$ y se vuelve a ampliar), y `control`, sin desenfoque. El vehículo nunca se desenfoca. En ambas variantes se aplica un gradiente alfa lineal de 5–10 px hacia adentro en los cuatro bordes del recorte, limitado al 15 % de su lado menor. La etiqueta sigue siendo el rectángulo completo del recorte.

Cada variante está en `data/synthetic/matched/` o `data/synthetic/control/` y contiene `images/`, `labels/`, `data.yaml` y `manifest.jsonl`. El manifiesto registra el fondo y sus atributos, la ventana de recorte, el vehículo, los tamaños, la fracción, la escala, el factor de desenfoque, el gradiente, la posición, el reflejo, la semilla y los rechazos.

3.5. Limitaciones y riesgos

- Los vehículos que ya aparecen en los fondos no se filtran ni se etiquetan. Si YOLO los detecta, pueden contarse como falsos positivos.

	Mín.	p5	p25	Mediana	p75	p95	Máx.
Escala s	0.71	1.17	1.82	2.35	3.10	4.64	7.19
Fracción de área	0.401	0.407	0.466	0.509	0.561	0.588	0.596

Tabla 7: Distribución observada en las 100 escenas de cada variante (idéntica en `matched` y `control`). La fracción media es 0.507.

Rango de s	≤ 1	$(1, 2]$	$(2, 3]$	$(3, 4]$	> 4
Escenas	3	28	41	18	10

Tabla 8: Escenas por rango de ampliación. En `matched`, 10 escenas (10 %) alcanzan el tope de desenfoque $b = 4$; en `control`, ninguna aplica desenfoque. Hubo 3 rechazos por relación de aspecto.

- La ampliación necesaria para ocupar 40–60 % deja al vehículo más borroso que el fondo; el desenfoque dirigido (`matched`) y la variante de control sirven para medir este desajuste.
- El 39.9 % de las imágenes de fondo (797 de 2 000) tiene reflejo en el parabrisas.
- La etiqueta es el rectángulo completo del recorte, con su margen de fondo original y el borde suavizado, por lo que el IoU máximo realista queda por debajo de 1.
- No hay máscaras ni collage. Las licencias requieren verificación.

3.6. Reproducibilidad

La descarga con el script oficial se ejecuta manualmente y fuera del repositorio. Ningún comando de esta sección incluye credenciales.

```
python scripts/streetscapes_tools.py select --seed 0 \
    --candidate-frac 0.01 --n 2000 --oversample 1.25
python scripts/streetscapes_tools.py verify --keep 2000
python scripts/prepare_backgrounds_streetscapes.py
python scripts/make_synthetic.py --config configs/synthetic.yaml
python scripts/preview_synthetic.py
python scripts/dataset_stats.py
python scripts/run_detection.py --models n s \
    --data-variants matched control
```

4. Registro de decisiones

Todas las decisiones se tomaron el 12 de octubre de 2026.

ID	Decisión	Motivo y alternativas descartadas	Estado
D01	VeRi es el dataset principal; se usan recortes completos de *test*.	Evitar fuga de información. Alternativas: usar *train*; máscaras.	Decidido
D02	Lienzo de 640×640.	Tamaño estándar para el detector.	Decidido
D03	Abandonar COCO como fondo.	Escenas incoherentes, 45 fondos y umbrales de tamaño inadecuados. Alternativa: mantener COCO.	Decidido

ID	Decisión	Motivo y alternativas descartadas	Estado
D04	Forzar 40–60 % del área del lienzo.	La mediana de *test* ocupa 10.5 % del lienzo y requiere ampliación. Alternativa: tamaño sin forzar.	Decidido
D05	Usar Global Streetscapes.	Mayor coherencia de escenas urbanas. Alternativa: COCO.	Decidido
D06	Filtros contextuales y muestreo de Streetscapes.	Escenas diurnas, de calidad buena, de conducción y en perspectiva.	Decidido
D07	Conservar 2 000 imágenes válidas.	2 414 válidas de 2 500; 86 faltantes; 0 corruptas; lado menor máximo 4 176 en las válidas y 3 456 en las 2 000 conservadas.	Decidido
D08	No filtrar vehículos del fondo.	Riesgo conocido de falsos positivos. Alternativas: segmentar o excluir.	Decidido
D09	Un recorte de calle por escena.	Evitar collage.	Decidido
D10	Desenfoque `matched` (tope 4) y variante `control`.	Igualar el desajuste de resolución y poder medir su efecto. Alternativa: desenfoque siempre.	Decidido
D11	Gradiente alfa de 5–10 px.	Reducir el borde artificial sin cambiar la caja. Alternativas: sin gradiente; máscaras.	Decidido
D12	Licencia y vehículos de fondo.	Licencias discrepantes y objetos sin etiquetar. Resolver antes de los resultados finales.	Pendiente
D13	Evaluar solo el vehículo detectado más grande por imagen.	Se conserva la detección de mayor área con confianza $\geq 0{,}25$ y se compara con la etiqueta; las demás se cuentan aparte. Alternativa: todos los objetos.	Decidido

5. Detección con YOLO26

Se usan YOLO26n y YOLO26s (pesos `yolo26n.pt` y `yolo26s.pt`) para localizar vehículos. Las clases `car`, `bus` y `truck` de COCO se tratan como `vehicle`, la clase única del dataset sintético.

5.1. Protocolo de evaluación

1. Se ejecuta el modelo una vez por imagen con confianza mínima 0.05 y se guardan todas las detecciones de vehículo.
2. Se descartan las de confianza menor a 0.25 y se conserva *solo la de mayor área.*
3. Se calcula el IoU contra la caja etiquetada.
4. Las demás detecciones no se pierden: se cuentan por imagen como detecciones extra.

Métricas. Tasa de detección (imágenes con predicción); recall a IoU 0.5 y 0.75 (las imágenes sin predicción cuentan como fallo); IoU medio (0 si no hay predicción); AP50 y AP promedio de 0.5 a 0.95, calculadas con una sola predicción por imagen (por tanto, no comparables con el mAP publicado de COCO); detecciones extra por imagen; latencia de inferencia por imagen; y pico de VRAM asignada por PyTorch.

6. Descriptores

6.1. Atributos fijos

PENDIENTE: arquitectura, entrenamiento y resultados del clasificador multicabeza de color y tipo.

6.2. Descripción generativa

PENDIENTE: modelo visión–lenguaje, instrucciones, normalización y evaluación.

7. Base de datos

MongoDB (probable), con un documento por objeto detectado. **PENDIENTE:** esquema de documentos, índices y consultas.

8. LocateAnything

Prueba secundaria con el modelo reducido `locate-anything-q8_0` en GPU, como alternativa de localización frente a YOLO26. Su salida es un JSON con cajas y etiquetas, y una imagen anotada; su calidad depende del tamaño del modelo, de la cuantización y del *prompt*. **PENDIENTE:** configuración, datos de prueba y comparación con YOLO26.

9. Resultados

9.1. Detección con YOLO26 sobre el dataset sintético

Evaluación sobre las 100 escenas de cada variante, con confianza mínima 0.25 y selección del vehículo más grande.

Modelo	Datos	Detección	R@0.5	R@0.75	IoU medio	AP50	AP50–95	Extra	ms	VRAM (MB)
YOLO26n	matched	0.920	0.830	0.700	0.706	0.765	0.484	1.50	2.89	227
YOLO26n	control	0.960	0.870	0.720	0.732	0.823	0.509	1.65	2.31	227
YOLO26s	matched	0.980	0.920	0.780	0.783	0.881	0.563	1.79	4.65	438
YOLO26s	control	0.990	0.900	0.770	0.765	0.864	0.549	2.09	4.51	438

Tabla 10: Resultados de detección. “Extra” es la media de detecciones adicionales por imagen; “ms” es la inferencia media por imagen.

Lectura. YOLO26s supera a YOLO26n en recall, IoU y AP, con una inferencia entre 1.6 y 2 veces más lenta y casi el doble de memoria. Con 100 imágenes por variante, una imagen vale un punto porcentual y el error típico de un recall cercano a 0.85 ronda los 3 a 4 puntos, así que las diferencias entre `matched` y `control` (1 a 4 imágenes) no permiten concluir nada sobre el efecto del desenfoque. Parte de la caída entre R@0.5 y R@0.75 se debe a que la etiqueta incluye el margen del recorte de VeRi, por lo que el IoU máximo realista es menor que 1. Las detecciones extra (1.5 a 2.1 por imagen) reflejan los vehículos reales del fondo, no etiquetados.

PENDIENTE: repetir con al menos 1 000 imágenes por variante, comparación pareada imagen a imagen, resultados por rango de escala y mediciones de latencia con calentamiento.

9.2. Resto de resultados

PENDIENTE: resultados de descriptores, base de datos y LocateAnything.

10. Bitácora de experimentos

Todas las entradas corresponden al 12 de octubre de 2026.

ID	Experimento	Configuración y resultado
V1	Dataset sintético con fondos COCO	COCO val2017, 45 fondos, 100 PNG de 640 × 640, tamaño por lado mayor log-uniforme sin ampliar. Abandonado (sección 3.3). Huella SHA-256 del manifiesto: 67f2e6d0573f86708246d0a6…
V2-m	Dataset sintético V2, variante `matched`	2 000 fondos de Streetscapes, 100 escenas, 40–60 % de área, desenfoque $b = \text{mín}(s, 4)$, gradiente 5–10 px. Huella SHA-256 del manifiesto: ba41206620e409c6…
V2-c	Dataset sintético V2, variante `control`	Misma geometría que `matched`, sin desenfoque de fondo. Huella SHA-256 del manifiesto: d6fbcd523028c68b…
DET-1	Detección YOLO26n y YOLO26s	Evaluación con el vehículo más grande (confianza $\geq 0{,}25$) sobre `matched` y `control`; resultados en la Tabla de la sección 9.

11. Conclusiones

PENDIENTE: conclusiones, limitaciones observadas y trabajo futuro.